

APRENDIZAJE AUTOMÁTICO

ACTIVIDAD 3ER CORTE

Programación Dinámica y Control Monte Carlo

Entregable: un notebook .ipynb completamente ejecutado, organizado con celdas de código y celdas de texto para el análisis. El notebook debe ser reproducible por cualquier persona que lo ejecute.

Cada grupo trabajará con un entorno diferente: un grupo trabajará con Taxi-v3 y otro grupo con FrozenLake 8×8.

1. Exploración del entorno

Describan el espacio de estados, el espacio de acciones, la función de recompensa y las condiciones de finalización del episodio en su entorno. Ejecuten un episodio completo con una política aleatoria y muéstrenlo usando `env.render()`. Calculen la recompensa promedio de la política aleatoria sobre 500 episodios.

Para FrozenLake 8×8, además, deben demostrar el efecto del resbalamiento: ejecuten varias veces la misma acción desde el mismo estado y muestren que el estado resultante puede variar.

Argumenten si la Programación Dinámica es aplicable en su entorno y por qué, conectando esta explicación con la discusión realizada en el notebook de Monte Carlo sobre Blackjack.

2. Programación Dinámica (PD)

Implementen Iteración de Política e Iteración de Valores en su entorno. Pueden reutilizar y adaptar el código del notebook de Programación Dinámica visto en clase.

Para cada algoritmo, grafiquen el delta de convergencia frente al número de iteraciones. Evalúen la política óptima obtenida sobre 1000 episodios y reporten tasa de éxito y recompensa media.

Incluyan una tabla que compare los dos algoritmos en número de iteraciones hasta convergencia, tiempo de cómputo aproximado, recompensa media y tasa de éxito final. Después de la tabla, discutan cuál de los dos algoritmos converge más rápido en su entorno y por qué creen que ocurre eso.

3. Control Monte Carlo (MC)

Implementen MC Control on-policy con el algoritmo ϵ -greedy usando tres valores: $\epsilon = 0.05$, $\epsilon = 0.15$ y $\epsilon = 0.30$. Usen el mismo número de episodios de entrenamiento para los tres valores de ϵ y repórtenlo claramente.

Para cada valor de ϵ , entrenen la política, grafiquen la recompensa media por episodio con una ventana deslizante de 500 episodios, evalúen la política final sobre 1000 episodios y reporten tasa de éxito y recompensa media.

Incluyan una tabla con ϵ , episodios de entrenamiento, tasa de éxito y recompensa media. Luego expliquen cómo afecta ϵ al aprendizaje: ¿con cuál valor aprende más rápido?, ¿con cuál valor obtiene mejor política final?, ¿qué ocurre cuando el agente explora demasiado? y ¿qué ocurre cuando explora muy poco?

4. Efecto de γ en Monte Carlo

Después de elegir el mejor valor de ϵ , repitan el entrenamiento de MC on-policy variando el factor de descuento: $\gamma = 0.7$, $\gamma = 0.9$ y $\gamma = 0.99$. No es necesario hacer una búsqueda completa de combinaciones; solo usen el mejor valor de ϵ encontrado en el punto anterior.

Para cada valor de γ , entrenen MC on-policy, evalúen la política sobre 1000 episodios, reporten tasa de éxito y recompensa media, y visualicen la política aprendida o algunos valores Q representativos.

Incluyan una tabla con γ , ϵ usado, tasa de éxito y recompensa media. Luego expliquen cómo cambia el comportamiento del agente cuando γ es bajo o alto. Por ejemplo, con γ bajo el agente da más importancia a recompensas cercanas, mientras que con γ alto considera más las recompensas futuras.

5. Comparación PD vs. Monte Carlo

Grafiquen la curva de desempeño del mejor MC on-policy y tracen sobre ella una línea horizontal con la tasa de éxito alcanzada por el mejor método de Programación Dinámica. Esto permitirá observar cuántos episodios necesita Monte Carlo para acercarse al desempeño de Programación Dinámica.

Finalmente, respondan:

- ¿cuál método logró mejor desempeño?
- ¿cuál fue más rápido?
- ¿cuál fue más fácil de implementar?
- ¿qué ventajas y limitaciones tiene Programación Dinámica?
- ¿qué ventajas y limitaciones tiene Monte Carlo?
- ¿en qué tipo de problemas reales usarían cada método?